

# “Machine Learning estadístico para interfaces Cerebro-Computadora”

Repaso álgebra lineal

**Dra. Victoria Peterson**

`vpeterson@santafe-conicet.gov.ar`

Nov 2023



NiCALab



NiCALab



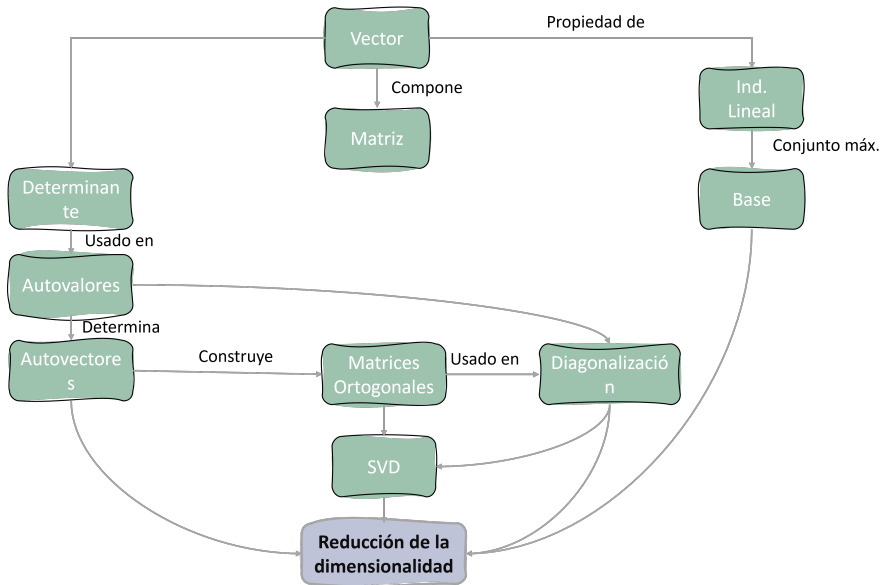
CONICET



I M A L



# Álgebra lineal all around





# Autovalores y autovectores

## Valores *proprios*

“Caracterizadores de una matriz”

### Definición

Def. 4.6. MML Book

Sea  $\mathbf{A} \in \mathbb{R}^{n \times n}$  una matriz cuadrada. Luego,  $\lambda \in \mathbb{R}$  es un autovalor de  $\mathbf{A}$  y  $\mathbf{x} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$  es el correspondiente autovector de  $\mathbf{A}$  si

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}$$

o que es lo mismo

$$(\mathbf{A} - \lambda\mathbf{I}_n)\mathbf{x} = \mathbf{0}$$



# Autovalores y autovectores

## Valores *propios*

“Caracterizadores de una matriz”

### Definición

Def. 4.6. MML Book

Sea  $\mathbf{A} \in \mathbb{R}^{n \times n}$  una matriz cuadrada. Luego,  $\lambda \in \mathbb{R}$  es un autovalor de  $\mathbf{A}$  y  $\mathbf{x} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$  es el correspondiente autovector de  $\mathbf{A}$  si

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}$$

o que es lo mismo

$$(\mathbf{A} - \lambda\mathbf{I}_n)\mathbf{x} = \mathbf{0}$$

“Multiplicación matriz-vector igual a una multiplicación escalar”


# Autovalores y autovectores

## Matrices como transformaciones lineales

1. Repaso

2. SVD

3. Machete



NiCALab

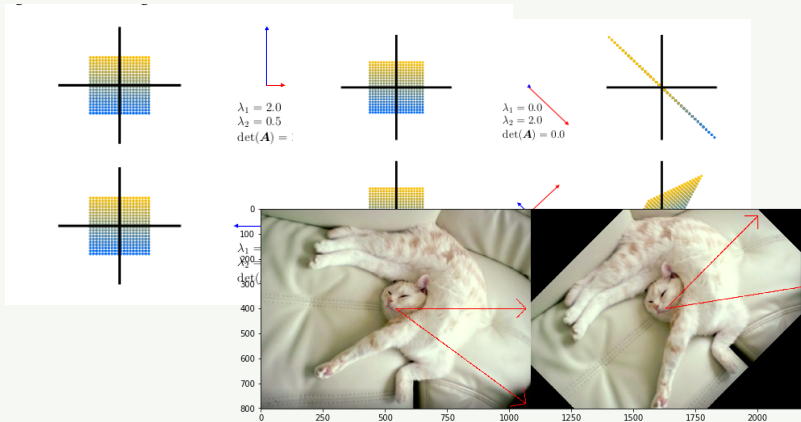
# Autovalores y autovectores

## 1. Repaso

## 2. SVD

## 3. Machete

## Matrices como transformaciones lineales



NiCALab



# Autovalores y autovectores

## Computo

- Resolver  $\det(\mathbf{A} - \lambda \mathbf{I}) = 0$
- Hallar los autovectores correspondientes a cada autovalor hallado mediante:

$$\begin{bmatrix} a_{11} - \lambda & a_{12} \\ a_{21} & a_{22} - \lambda \end{bmatrix} \mathbf{x} = \mathbf{0}$$



# Descomposición en valores propios (EVD)

## Teorema

Def. 4.20. MML Book

Una matriz cuadrada  $\mathbf{A} \in \mathbb{R}^{n \times n}$  puede ser factorizada en

$$\mathbf{A} = \mathbf{P}\mathbf{D}\mathbf{P}^{-1},$$

donde  $\mathbf{P} \in \mathbb{R}^{n \times n}$  y  $\mathbf{D}$  es una **matriz diagonal** cuyos valores en la diagonal son los **autovalores** de  $\mathbf{A}$ , si y sólo si los **autovectores** de  $\mathbf{A}$  forman una **base** en  $\mathbb{R}$ .





# Descomposición en valores propios (EVD)

## Teorema

Def. 4.20. MML Book

Una matriz cuadrada  $\mathbf{A} \in \mathbb{R}^{n \times n}$  puede ser factorizada en

$$\mathbf{A} = \mathbf{P}\mathbf{D}\mathbf{P}^{-1},$$

donde  $\mathbf{P} \in \mathbb{R}^{n \times n}$  y  $\mathbf{D}$  es una **matriz diagonal** cuyos valores en la diagonal son los **autovalores** de  $\mathbf{A}$ , si y sólo si los **autovectores** de  $\mathbf{A}$  forman una **base** en  $\mathbb{R}$ .




Fig. 4.7 - MML Book



# Descomposición en valores propios (EVD)

## Teorema

Def. 4.20. MML Book

Una matriz cuadrada  $\mathbf{A} \in \mathbb{R}^{n \times n}$  puede ser factorizada en

$$\mathbf{A} = \mathbf{P}\mathbf{D}\mathbf{P}^{-1},$$

donde  $\mathbf{P} \in \mathbb{R}^{n \times n}$  y  $\mathbf{D}$  es una **matriz diagonal** cuyos valores en la diagonal son los **autovalores** de  $\mathbf{A}$ , si y sólo si los **autovectores** de  $\mathbf{A}$  forman una **base** en  $\mathbb{R}$ .




Fig. 4.7 - MML Book

## Transformaciones Lineales



# Descomposición en valores propios (EVD)

## Teorema

Def. 4.20. MML Book

Una **matriz cuadrada**  $\mathbf{A} \in \mathbb{R}^{n \times n}$  puede ser factorizada en

$$\mathbf{A} = \mathbf{P}\mathbf{D}\mathbf{P}^{-1},$$

donde  $\mathbf{P} \in \mathbb{R}^{n \times n}$  y  $\mathbf{D}$  es una **matriz diagonal** cuyos valores en la diagonal son los **autovalores** de  $\mathbf{A}$ , si y sólo si los **autovectores** de  $\mathbf{A}$  forman una **base** en  $\mathbb{R}$ .




Fig. 4.7 - MML Book

## Transformaciones Lineales



# SVD

## Formulación

Sea  $\mathbf{A} \in \mathbb{R}^{m \times n}$ , una matriz rectangular de rango  $r \in [0, \min(m, n)]$  la descomposición en SVD de  $\mathbf{A}$  es una descomposición de la forma:

$$\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T,$$

donde  $\mathbf{U} \in \mathbb{R}^{m \times m}$  **matriz ortogonal** con vectores columna  $\mathbf{u}_i$ ,  $i = 1, \dots, m$ ,  $\mathbf{V} \in \mathbb{R}^{n \times n}$  **matriz ortogonal** con vectores columna  $\mathbf{v}_j$ ,  $j = 1, \dots, n$  y  $\Sigma \in \mathbb{R}^{m \times n}$  matriz diagonal tal que  $\Sigma_i = \sigma_i \geq 0$ .



# SVD

## Formulación

Sea  $\mathbf{A} \in \mathbb{R}^{m \times n}$ , una matriz rectangular de rango  $r \in [0, \min(m, n)]$  la descomposición en SVD de  $\mathbf{A}$  es una descomposición de la forma:

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T,$$

donde  $\mathbf{U} \in \mathbb{R}^{m \times m}$  **matriz ortogonal** con vectores columna  $\mathbf{u}_i$ ,  $i = 1, \dots, m$ ,  $\mathbf{V} \in \mathbb{R}^{n \times n}$  **matriz ortogonal** con vectores columna  $\mathbf{v}_j$ ,  $j = 1, \dots, n$  y  $\mathbf{\Sigma} \in \mathbb{R}^{m \times n}$  matriz diagonal tal que  $\Sigma_i = \sigma_i \geq 0$ .

$$\begin{matrix} n \\ \boxed{\mathbf{A}} \end{matrix} = \begin{matrix} m \\ \boxed{\mathbf{U}} \end{matrix} \begin{matrix} m & n \\ \boxed{\mathbf{\Sigma}} \end{matrix} \begin{matrix} n \\ \boxed{\mathbf{V}^T} \end{matrix}$$

Fig. 10.2 - MML Book



## SVD

## Formulación

Sea  $\mathbf{A} \in \mathbb{R}^{m \times n}$ , una matriz rectangular de rango  $r \in [0, \min(m, n)]$  la descomposición en SVD de  $\mathbf{A}$  es una descomposición de la forma:

$$\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T,$$

donde  $\mathbf{U} \in \mathbb{R}^{m \times m}$  **matriz ortogonal** con vectores columna  $\mathbf{u}_i, i = 1, \dots, m$ ,  $\mathbf{V} \in \mathbb{R}^{n \times n}$  **matriz ortogonal** con vectores columna  $\mathbf{v}_j, j = 1, \dots, n$  y  $\Sigma \in \mathbb{R}^{m \times n}$  matriz diagonal tal que  $\Sigma_i = \sigma_i \geq 0$ .

$\mathbf{u}_i, i = 1, \dots, m$ : vectores singulares izquierdos  
 $\mathbf{v}_j, j = 1, \dots, n$ : vectores singulares derechos  
 $\sigma_i, i = 1, \dots, r$ : valores singulares.

$$\begin{matrix} n \\ \boxed{\mathbf{A}} \end{matrix} = \begin{matrix} m \\ \boxed{\mathbf{U}} \end{matrix} \begin{matrix} m & n \\ \boxed{\Sigma} \end{matrix} \begin{matrix} n \\ \boxed{\mathbf{V}^T} \end{matrix}$$

Fig. 10.2 - MML Book

# SVD

## Computo

- 1 Cálculo de los vectores singulares derechos mediante descomposición en valores propios.
- 2 Cálculo de la matriz de valores singulares.
- 3 Cálculo de los vectores singulares izquierdos como la imagen normalizada de los vectores singulares derechos.





# SVD

## Aproximación de matrices

Una matriz  $\mathbf{A} \in \mathbb{R}^{m \times n}$  de rango  $r$  puede escribirse como la suma de matrices  $\mathbf{A}_i$  de rango-1 tal que:

$$\mathbf{A} = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T = \sum_{i=1}^r \sigma_i \mathbf{A}_i.$$

Por lo tanto es fácil de ver que podemos obtener una aproximación de  $\mathbf{A}$  mediante la suma de las primeras  $k$  matrices de rango-1:

$$\hat{\mathbf{A}}(k) \triangleq \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T = \sum_{i=1}^k \sigma_i \mathbf{A}_i.$$





# SVD

## Aproximación de matrices

Una matriz  $\mathbf{A} \in \mathbb{R}^{m \times n}$  de rango  $r$  puede escribirse como la suma de matrices  $\mathbf{A}_i$  de rango-1 tal que:

$$\mathbf{A} = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T = \sum_{i=1}^r \sigma_i \mathbf{A}_i.$$

Por lo tanto es fácil de ver que podemos obtener una aproximación de  $\mathbf{A}$  mediante la suma de las primeras  $k$  matrices de rango-1:

$$\hat{\mathbf{A}}(k) \triangleq \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T = \sum_{i=1}^k \sigma_i \mathbf{A}_i.$$

La aproximación de matrices mediante SVD es una aproximación de mínima norma (ver Teo 4.25)

# SVD

## Aproximación de matrices: error de aproximación

Sea  $\mathbf{A} \in \mathbb{R}^{m \times n}$  una matriz de rango  $r$  y sea  $\mathbf{B} \in \mathbb{R}^{m \times n}$  una matriz de rango  $k$ , para cualquier  $k \leq r$  con  $\hat{\mathbf{A}}(k) = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T$  se muestra que:

$$\hat{\mathbf{A}}(k) = \operatorname{argmin}_{\operatorname{rank}(\mathbf{B})=k} \|\mathbf{A} - \mathbf{B}\|$$

$$\|\mathbf{A} - \hat{\mathbf{A}}\|_2 = \sigma_{k+1}^*$$



# SVD

## Aproximación de matrices: error de aproximación

Sea  $\mathbf{A} \in \mathbb{R}^{m \times n}$  una matriz de rango  $r$  y sea  $\mathbf{B} \in \mathbb{R}^{m \times n}$  una matriz de rango  $k$ , para cualquier  $k \leq r$  con  $\hat{\mathbf{A}}(k) = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T$  se muestra que:

$$\hat{\mathbf{A}}(k) = \operatorname{argmin}_{\operatorname{rank}(\mathbf{B})=k} \|\mathbf{A} - \mathbf{B}\|$$

$$\|\mathbf{A} - \hat{\mathbf{A}}\|_2 = \sigma_{k+1}^*$$

\* La norma espectral de  $\mathbf{A}$  es igual a su valor singular más grande  $\sigma_1$



# Notación

## Notación

$\mathbf{X} \in \mathbb{R}^{N \times D}$ : matriz de N observaciones

$\mathbf{x} \in \mathbb{R}^D$ : vector D-dimensional de atributos/features/covariables

$f(\cdot)$ : función  $f: \mathbb{R}^D \rightarrow \mathbb{R}$

$\mathbf{y} \in \mathbb{R}^N$ : vector N-dimensional. Variable dependiente, target.



# Definiciones

## Matriz ortogonal

Def. 3.8. MML Book

Una matriz cuadrada  $\mathbf{A} \in \mathbb{R}^{n \times n}$  es una matriz ortogonal si y sólo si sus columnas son ortogonales, es decir:

$$\mathbf{A}\mathbf{A}^T = \mathbf{I} = \mathbf{A}^T\mathbf{A}$$

$\Rightarrow$

$$\mathbf{A}^T = \mathbf{A}^{-1}$$





# Definiciones

## Teorema Espectral

Teo. 4.15. MML Book

Si  $\mathbf{A} \in \mathbb{R}^{n \times n}$  es simétrica, existe una base ortonormal del espacio vectorial  $V$  correspondiente que consiste en los autovectores de  $\mathbf{A}$  y cada autovalor es real.

## Colorario

La descomposición en valores propios de una matriz  $\mathbf{A}$  existe, y puede encontrarse una base ortogonal de autovectores tal que  $\mathbf{A} = \mathbf{P}\mathbf{D}\mathbf{P}^T$ , donde  $\mathbf{D}$  es diagonal y las columnas de  $\mathbf{P}$  contienen los autovectores.

# Definiciones

## Norma espectral de una matriz

Teo. 4.23. MML Book

Para  $\mathbf{x} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$ , la norma espectral de una matriz  $\mathbf{A} \in \mathbb{R}^{m \times n}$  está definida como:

$$\|\mathbf{A}\|_2 \triangleq \max_{\mathbf{x}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}$$

La norma espectral determina la longitud máxima que puede tomar cualquier vector  $\mathbf{x}$  al multiplicarse por  $\mathbf{A}$ .

