

# “Machine Learning estadístico para interfaces Cerebro-Computadora”

MODULO II - parte II

**Dra. Victoria Peterson**

[vpeterson@santafe-conicet.gov.ar](mailto:vpeterson@santafe-conicet.gov.ar)



NiCALab

Nov 2023



CONICET



I M A L

# Filtrado Espacial: Recap

not observable  
source space  
Neural sources

observable  
sensor space

Brain recordings

Estimated sources

$$\mathbf{X} = \mathbf{A}\mathbf{S}$$

↳ Spatial patterns


Forward model

$$\hat{\mathbf{S}} = \mathbf{W}^T \mathbf{X}$$


↳ **Spatial filters**

Backward model


Feature learning



Referencing



Denoising



- 1 Filtrado Espacial en Denoising
  - Análisis de componentes principales (PCA)
  - Análisis de componentes Independientes (ICA)


## 1 Filtrado Espacial en Denoising

- Análisis de componentes principales (PCA)
- Análisis de componentes Independientes (ICA)

# Motivación

not observable  
*source space*

Neural sources




Linear  
mixing



observable  
*sensor space*

Brain recordings




# Motivación

not observable

*source space*

Neural sources &  
non-neural sources




Linear  
mixing



observable

*sensor space*


Brain recordings



# Motivación

not observable  
*source space*

Neural sources &  
non-neural sources




Linear  
mixing



observable  
*sensor space*


Brain recordings



Linear  
unmixing




Estimated sources



# Motivación

not observable  
*source space*

Neural sources &  
non-neural sources




Linear  
mixing



observable  
*sensor space*


Brain recordings



Linear  
unmixing




Estimated sources



Low-rank  
factorization



Denoised signals






# Motivación

not observable  
*source space*

Neural sources &  
non-neural sources




Linear  
mixing



observable  
*sensor space*


Brain recordings



Linear  
unmixing




Estimated sources



Low-rank  
factorization




Denoised signals



¿Podremos encontrar una matriz de transformación  $W$  tal que los componentes de artefacto sean estimados?

- 1 Filtrado Espacial en Denoising
  - Análisis de componentes principales (PCA)
  - Análisis de componentes Independientes (ICA)

“Hallar el subespacio en el cuál la varianza de los datos sea maximizada”




From: [Rao, 2013]

## Formulación

$$\mathbf{w} = \operatorname{argmax} \{ \mathbf{w}^T \Sigma \mathbf{w} \} \quad \text{s.t. } \|\mathbf{w}\| = 1,$$

donde  $\Sigma \doteq \frac{1}{p} \tilde{X} \tilde{X}^T$ , con  $\tilde{X} \in \mathbb{R}^{N_c \times p}$  matriz de datos de EEG de media cero de dimensión  $p$  (datos crudos o época concatenadas).

“Hallar el subespacio en el cuál la varianza de los datos sea maximizada”



From: [Rao, 2013]

## Formulación

$$\mathbf{w} = \operatorname{argmax} \{ \mathbf{w}^T \Sigma \mathbf{w} \} \quad \text{s.t. } \|\mathbf{w}\| = 1,$$

donde  $\Sigma \doteq \frac{1}{p} \tilde{X} \tilde{X}^T$ , con  $\tilde{X} \in \mathbb{R}^{N_c \times p}$  matriz de datos de EEG de media cero de dimensión  $p$  (datos crudos o época concatenadas).

Resolución via Lagrange Multipliers

Sean  $x_1, \dots, x_p$  nuestro conjunto de variables originales, y sea  $z_i$ ,  $i = 1, \dots, p$  una combinación lineal de esas variaciones:

$$z_i = \sum_{j=1}^{N_c} w_{i,j} x_j.$$

Sean  $x_1, \dots, x_p$  nuestro conjunto de variables originales, y sea  $z_i$ ,  $i = 1, \dots, p$  una combinación lineal de esas variaciones:

$$z_i = \sum_{j=1}^{N_c} w_{i,j} x_j.$$

$$\text{var}(z_i) = \mathbf{w}_i^T \Sigma \mathbf{w}_i,$$

Sean  $x_1, \dots, x_p$  nuestro conjunto de variables originales, y sea  $z_i$ ,  $i = 1, \dots, p$  una combinación lineal de esas variaciones:

$$z_i = \sum_{j=1}^{N_c} w_{i,j} x_j.$$

$$\text{var}(z_i) = \mathbf{w}_i^T \Sigma \mathbf{w}_i,$$

⇒ El autovector correspondiente al autovalor  $\sigma$  más grande de  $\Sigma$  será el **primer componente principal**.

Sean  $x_1, \dots, x_p$  nuestro conjunto de variables originales, y sea  $z_i$ ,  $i = 1, \dots, p$  una combinación lineal de esas variaciones:

$$z_i = \sum_{j=1}^{N_c} w_{i,j} x_j.$$

$$\text{var}(z_i) = \mathbf{w}_i^T \Sigma \mathbf{w}_i,$$

⇒ El autovector correspondiente al autovalor  $\sigma$  más grande de  $\Sigma$  será el **primer componente principal**.

⇒  $\mathbf{w}_i$  son los autovectores de  $\Sigma$



## Componentes principales, cantidad, aporte en la varianza

Cada componente principal aporta  $\frac{\sigma_i}{\sum \sigma_i}$ , a la varianza total, siendo  $\sigma_i$  el  $i$ -ésimo autovalor de  $\Sigma$ .

## Componentes principales, cantidad, aporte en la varianza

Cada componente principal aporta  $\frac{\sigma_i}{\sum \sigma_i}$ , a la varianza total, siendo  $\sigma_i$  el  $i$ -ésimo autovalor de  $\Sigma$ . Se suele elegir las componentes que representan el 90% de la varianza,

## Componentes principales, cantidad, aporte en la varianza

Cada componente principal aporta  $\frac{\sigma_i}{\sum \sigma_i}$ , a la varianza total, siendo  $\sigma_i$  el  $i$ -ésimo autovalor de  $\Sigma$ . Se suele elegir las componentes que representan el 90% de la varianza, o realizar una gráfica del espectro de los autovalores y seleccionar la cantidad de componentes mínima.

### Componentes principales, cantidad, aporte en la varianza

Cada componente principal aporta  $\frac{\sigma_i}{\sum \sigma_i}$ , a la varianza total, siendo  $\sigma_i$  el  $i$ -ésimo autovalor de  $\Sigma$ . Se suele elegir las componentes que representan el 90% de la varianza, o realizar una gráfica del espectro de los autovalores y seleccionar la cantidad de componentes mínima.

### Corrección de la media

PCA supone datos estandarizados (media cero, desvío uno). Para corregir esto simplemente:

$$\mathbf{z} = \mathbf{W}^T(\mathbf{x} - \boldsymbol{\mu})$$

### Componentes principales, cantidad, aporte en la varianza

Cada componente principal aporta  $\frac{\sigma_i}{\sum \sigma_i}$ , a la varianza total, siendo  $\sigma_i$  el  $i$ -ésimo autovalor de  $\Sigma$ . Se suele elegir las componentes que representan el 90% de la varianza, o realizar una gráfica del espectro de los autovalores y seleccionar la cantidad de componentes mínima.

### Corrección de la media

PCA supone datos estandarizados (media cero, desvío uno). Para corregir esto simplemente:

$$\mathbf{z} = \mathbf{W}^T(\mathbf{x} - \boldsymbol{\mu})$$

### Aproximación de los datos

La transformación  $\mathbf{W}$  es invertible. Definimos  $\mathbf{A} = (\mathbf{W}^T)^{-1}$  Entonces

$$\mathbf{x} = \mathbf{A}\mathbf{z} + \boldsymbol{\mu}$$

## Aproximación de los datos

La transformación  $\mathbf{A}$  es invertible. Entonces  $\mathbf{x} = \mathbf{A}\mathbf{z} + \boldsymbol{\mu}$ . Si  $k$ ,  $k < p$  componentes principales se utilizan:

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{z}_k + \boldsymbol{\mu}.$$

### Aproximación de los datos

La transformación  $\mathbf{A}$  es invertible. Entonces  $\mathbf{x} = \mathbf{A}\mathbf{z} + \boldsymbol{\mu}$ . Si  $k$ ,  $k < p$  componentes principales se utilizan:

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{z}_k + \boldsymbol{\mu}.$$

### Whitening y PCA

La transformación de “blanqueo” o transformación esférica es una transformación lineal que mapea un vector de variables aleatorias de matriz de covarianza conocida en un nuevo conjunto de variables cuya varianza es la identidad  $\mathbf{I}$ , es decir están decorrelacionados y su varianza es 1.


Mediante PCA:

$$\tilde{\mathbf{x}} = \mathbf{D}^{1/2} \mathbf{A}^T (\mathbf{x} - \boldsymbol{\mu}), \quad \text{siendo } \mathbf{D} = \text{diag}(\sigma_i).$$

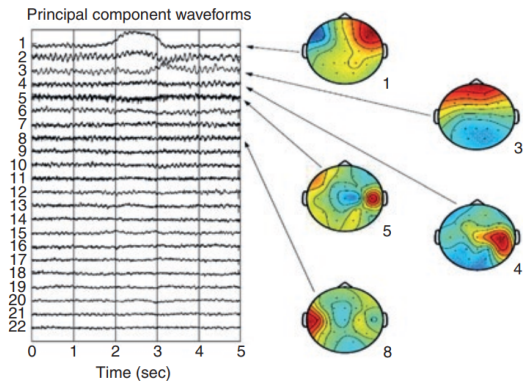
# Análisis de componentes principales (PCA)

[Rao, 2013]

## Aplicaciones en BCI



A



B


Fuente: [Rao, 2013]



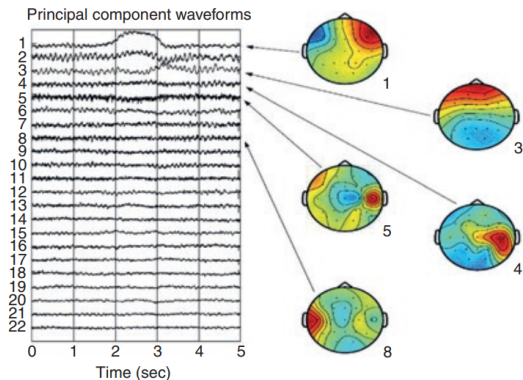
# Análisis de componentes principales (PCA)

[Rao, 2013]

## Aplicaciones en BCI



A



B

Fuente: [Rao, 2013]


¿Será siempre buena idea maximizar la varianza en el EEG?

- 1 Filtrado Espacial en Denoising
  - Análisis de componentes principales (PCA)
  - Análisis de componentes Independientes (ICA)

# Análisis de componentes Independientes (ICA)

[Oja and Hyvarinen, 2000]

“Maximizar la independencia entre componentes”




## Problem formulation in brief

Hallar  $W$  tal que  $\hat{\mathbf{s}} = W^T X$  sea *independiente*.

# Análisis de componentes Independientes (ICA)

[Oja and Hyvarinen, 2000]

“Maximizar la independencia entre componentes”



## Problem formulation in brief


Hallar  $W$  tal que  $\hat{s} = W^T X$  sea *independiente*.

Varias formas de atacar el problema!!!

# Análisis de componentes Independientes (ICA)

[Oja and Hyvarinen, 2000]

No-Gaussianidad e independencia



“No-Gaussianidad  
implica  
independencia”

# Análisis de componentes Independientes (ICA)

[Oja and Hyvarinen, 2000]

No-Gaussianidad e independencia

## Objetivo: maximizar la Negentropía

Una variable Gaussiana tiene mayor *entropía* entre todas las variables aleatorias de la misma varianza. Definimos la Negentropía de una v.a.  $\mathbf{y}$  mediante

$$N(\mathbf{y}) = H(\mathbf{y}_{gauss}) - H(\mathbf{y}),$$

donde  $H(\cdot)$  es la entropía y  $\mathbf{y}_{gauss}$  es una variable Gaussiana de misma covarianza que  $\mathbf{y}$

# Análisis de componentes Independientes (ICA)

[Oja and Hyvarinen, 2000]

No-Gaussianidad e independencia

## Objetivo: maximizar la Negentropía

Una variable Gaussiana tiene mayor *entropía* entre todas las variables aleatorias de la misma varianza. Definimos la Negentropía de una v.a.  $\mathbf{y}$  mediante

$$N(\mathbf{y}) = H(\mathbf{y}_{gauss}) - H(\mathbf{y}),$$

donde  $H(\cdot)$  es la entropía y  $\mathbf{y}_{gauss}$  es una variable Gaussiana de misma covarianza que  $\mathbf{y}$   $\Rightarrow$  Maximizar  $N(\mathbf{y})$  implica encontrar funciones no-Gaussianas

# Análisis de componentes Independientes (ICA)

[Oja and Hyvarinen, 2000]

No-Gaussianidad e independencia

## Objetivo: maximizar la Negentropía

Una variable Gaussiana tiene mayor *entropía* entre todas las variables aleatorias de la misma varianza. Definimos la Negentropía de una v.a.  $\mathbf{y}$  mediante

$$N(\mathbf{y}) = H(\mathbf{y}_{gauss}) - H(\mathbf{y}),$$

donde  $H(\cdot)$  es la entropía y  $\mathbf{y}_{gauss}$  es una variable Gaussiana de misma covarianza que  $\mathbf{y}$   $\Rightarrow$  Maximizar  $N(\mathbf{y})$  implica encontrar funciones no-Gaussianas

$\rightarrow$  difícil de computar  $\Rightarrow$  formulaciones para aproximar la negentropía son utilizadas



# Análisis de componentes Independientes (ICA)

[Oja and Hyvarinen, 2000]

Implementación

## Whitening

Variables independientes son siempre variables no correlacionadas

# Análisis de componentes Independientes (ICA)

[Oja and Hyvarinen, 2000]

Implementación

## Whitening

Variables independientes son siempre variables no correlacionadas  
⇒ el primer paso es hacer whitening de los datos

# Análisis de componentes Independientes (ICA)

[Oja and Hyvarinen, 2000]

Implementación

## Whitening

Variables independientes son siempre variables no correlacionadas  
⇒ el primer paso es hacer whitening de los datos  
⇒ PCA puede ser utilizado para blanquear los datos y reducir la dimensionalidad.

## Solvers


Diferentes solvers existen:

- FastICA: maximiza la no-Gaussianidad [Hyvarinen, 1999].
- Infomax: maximiza la información mutua [Bell and Sejnowski, 1995, Lee et al., 1999].
- PICCARD: maximiza la verosimilitud [?].

# Análisis de Componentes Independientes (ICA)


[Rao, 2013]

## Aplicaciones en BCI




Fuente: [Rao, 2013]

# PCA + ICA denoising pipeline



# PCA + ICA denoising pipeline



# Bibliografía utilizada I

- Bell, A. J. and Sejnowski, T. J. (1995). An information-maximization approach to blind separation and blind deconvolution. *Neural computation*, 7(6):1129–1159.
- Hotelling, H. (1933). Analysis of a complex of statistical variables into principal components. *Journal of educational psychology*, 24(6):417.
- Hyvarinen, A. (1999). Fast and robust fixed-point algorithms for independent component analysis. *IEEE transactions on Neural Networks*, 10(3):626–634.
- Lee, T.-W., Girolami, M., and Sejnowski, T. J. (1999). Independent component analysis using an extended infomax algorithm for mixed subgaussian and supergaussian sources. *Neural computation*, 11(2):417–441.
- Oja, E. and Hyvarinen, A. (2000). Independent component analysis: algorithms and applications. *Neural networks*, 13(4-5):411–430.
- Rao, R. P. N. (2013). *Brain-computer interfacing: an introduction*. Cambridge University Press.
- Webb, A. R. (2003). *Statistical pattern recognition*. John Wiley & Sons.