

“Machine Learning estadístico para interfaces Cerebro-Computadora”

MODULO III - parte III

Dra. Victoria Peterson

vpeterson@santafe-conicet.gov.ar



NiCALab

Nov 2023



CONICET



I M A L


1 Geometría Riemanniana

2 Desafíos de ML en BCI

1 Geometría Riemanniana


2 Desafíos de ML en BCI

La matrices de covarianza espaciales



Fuente: [pyRiemann](#)

La matrices de covarianza espaciales



Fuente: [pyRiemann](#)


¿Podré trabajar directamente en el espacio de las matrices de covarianza?

Geometría Riemanniana

Definiciones-preliminares

Variedad (Manifold) de Riemannian

Una variedad de Riemannian es una variedad diferenciable en el cual el plano tangente en cada punto es un espacio Euclideo.



Fuente: [Congedo et al., 2017]

Definiciones

$S(p) = \{\mathbf{S} \in M(p), \mathbf{S}^T = \mathbf{S}\}$, es el espacio de todas las matrices $p \times p$ simétricas en un espacio de matrices cuadradas.

$Q(p) = \{\mathbf{Q} \in S(p), \mathbf{Q} > 0\}$, es el conjunto de matrices $p \times p$ simétricas definidas-positivas (SPD).

Definiciones

$S(p) = \{\mathbf{S} \in M(p), \mathbf{S}^T = \mathbf{S}\}$, es el espacio de todas las matrices $p \times p$ simétricas en un espacio de matrices cuadradas.

$Q(p) = \{\mathbf{Q} \in S(p), \mathbf{Q} > 0\}$, es el conjunto de matrices $p \times p$ simétricas definidas-positivas (SPD).



Las matrices de covarianza Σ son SPD

Definiciones

$S(p) = \{\mathbf{S} \in M(p), \mathbf{S}^T = \mathbf{S}\}$, es el espacio de todas las matrices $p \times p$ simétricas en un espacio de matrices cuadradas.

$Q(p) = \{\mathbf{Q} \in S(p), \mathbf{Q} > 0\}$, es el conjunto de matrices $p \times p$ simétricas definidas-positivas (SPD).

Distancia de Riemannian

$\delta_R(\mathbf{\Sigma}_1, \mathbf{\Sigma}_2) = \|\text{Log}(\mathbf{\Sigma}_1^{-1} \mathbf{\Sigma}_2)\|_F = \left(\sum_{j=1}^p \log^2 \sigma_j \right)^{\frac{1}{2}}$, donde $\sigma_j = \text{eigen}(\mathbf{\Sigma}_1^{-1} \mathbf{\Sigma}_2)$

Propiedades:

- $\delta_R(\mathbf{\Sigma}_1, \mathbf{\Sigma}_2) = \delta_R(\mathbf{\Sigma}_2, \mathbf{\Sigma}_1)$.
- $\delta_R(\mathbf{\Sigma}_1, \mathbf{\Sigma}_2) = \delta_R(\mathbf{\Sigma}_1^{-1}, \mathbf{\Sigma}_2^{-1})$.
- $\delta_R(\mathbf{\Sigma}_1, \mathbf{\Sigma}_2) = \delta_R(\mathbf{W}^T \mathbf{\Sigma}_1 \mathbf{W}, \mathbf{W}^T \mathbf{\Sigma}_2 \mathbf{W})$, siendo \mathbf{W} una matriz $p \times p$ invertible.

Geometría Riemanniana

Definiciones-preliminares

Media aritmética

$$\bar{\Sigma}_a = \operatorname{argmin}_{\Sigma \in Q(p)} \sum_{i=1}^n \delta_E^2(\Sigma, \Sigma_i) = \frac{1}{n} \sum_{i=1}^n \Sigma_i.$$

Media de Reimannian

$$\bar{\Sigma}_R = \operatorname{argmin}_{\Sigma \in Q(p)} \sum_{i=1}^n \delta_R^2(\Sigma, \Sigma_i).$$

Geodésica

En el espacio de Riemannian de matrices SPD, se define como *geodésica* $\gamma(t)$, con $t \in [0, 1]$ a la distancia más corta entre dos puntos Σ_1 y Σ_2 ,

$$\gamma(t) = \Sigma_1^{1/2} (\Sigma_1^{-1/2} \Sigma_2 \Sigma_1^{-1/2})^t \Sigma_1^{1/2},$$

donde para cualquier matriz \mathbf{A} diagonalizable $\mathbf{A}^t = \mathbf{U} \mathbf{D}^t \mathbf{U}^{-1}$

Geometría Riemanniana

Definiciones-preliminares

Media aritmética

$$\bar{\Sigma}_a = \operatorname{argmin}_{\Sigma \in Q(p)} \sum_{i=1}^n \delta_E^2(\Sigma, \Sigma_i) = \frac{1}{n} \sum_{i=1}^n \Sigma_i.$$

Media de Reimannian

$$\bar{\Sigma}_R = \operatorname{argmin}_{\Sigma \in Q(p)} \sum_{i=1}^n \delta_R^2(\Sigma, \Sigma_i).$$

No tiene solución explícita. Debe hallarse mediante algoritmos iterativos.

Geodésica

En el espacio de Riemannian de matrices SPD, se define como *geodésica* $\gamma(t)$, con $t \in [0, 1]$ a la distancia más corta entre dos puntos Σ_1 y Σ_2 ,

$$\gamma(t) = \Sigma_1^{1/2} (\Sigma_1^{-1/2} \Sigma_2 \Sigma_1^{-1/2})^t \Sigma_1^{1/2},$$

donde para cualquier matriz \mathbf{A} diagonalizable $\mathbf{A}^t = \mathbf{U} \mathbf{D}^t \mathbf{U}^{-1}$

Geometría Riemanniana

Definiciones-preliminares

Media aritmética

$$\bar{\Sigma}_a = \operatorname{argmin}_{\Sigma \in Q(p)} \sum_{i=1}^n \delta_E^2(\Sigma, \Sigma_i) = \frac{1}{n} \sum_{i=1}^n \Sigma_i.$$

Recordar cálculo Σ_c en CSP.

Media de Reimannian

$$\bar{\Sigma}_R = \operatorname{argmin}_{\Sigma \in Q(p)} \sum_{i=1}^n \delta_R^2(\Sigma, \Sigma_i).$$

No tiene solución explícita. Debe hallarse mediante algoritmos iterativos.

Geodésica


En el espacio de Riemannian de matrices SPD, se define como *geodésica* $\gamma(t)$, con $t \in [0, 1]$ a la distancia más corta entre dos puntos Σ_1 y Σ_2 ,

$$\gamma(t) = \Sigma_1^{1/2} (\Sigma_1^{-1/2} \Sigma_2 \Sigma_1^{-1/2})^t \Sigma_1^{1/2},$$

donde para cualquier matriz \mathbf{A} diagonalizable $\mathbf{A}^t = \mathbf{U} \mathbf{D}^t \mathbf{U}^{-1}$

Geometría Riemanniana

Espacio tangente




Fuente: [Barachant et al., 2010]

$$\text{Log}_{\Sigma} : \Sigma(n) \rightarrow \mathbf{S}(n)$$

$$\text{Exp}_{\mathbf{S}} : \mathbf{S}(n) \rightarrow \Sigma(n)$$

Geometría Riemanniana

Espacio tangente




Fuente: [Barachant et al., 2010]

$$\text{Log}_{\Sigma}(\Sigma_i) = \mathbf{S}_i$$

$$\text{Exp}_{\mathbf{S}}(\mathbf{S}_i) = \Sigma_i$$

Geometría Riemanniana

Espacio tangente




Fuente: [Barachant et al., 2010]

$$\text{Log}_{\Sigma}(\Sigma_i) = \Sigma^{1/2} \text{Log}(\Sigma^{-1/2} \Sigma_i \Sigma^{-1/2}) \Sigma^{1/2}$$

$$\text{Exp}_{\Sigma}(\mathbf{S}_i) = \Sigma^{1/2} \text{Exp}(\Sigma^{-1/2} \mathbf{S}_i \Sigma^{-1/2}) \Sigma^{1/2}$$

Distancia mínima a la media Riemannian (MDM)



Distancia mínima a la media Riemannian (MDM)

Algorithm 1 Minimum Distance to Riemannian Mean

Input: a set of trials \mathbf{X}_i of K different known classes.

Input: \mathbf{X} an EEG trial of unknown class.

Input : $\mathcal{J}^{(k)}$ the set of indices of the trials corresponding to the k -th condition.

Output: \hat{k} the estimated class of test trial \mathbf{X} .

1: Compute SCMs of \mathbf{X}_i to obtain \mathbf{P}_i , (1).

2: Compute SCM of \mathbf{X} to obtain \mathbf{P} , (1).

3: **for** $k = 1$ to K **do**


4: $\mathbf{P}_{\mathcal{G}}^{(k)} = \mathcal{G}(\mathbf{P}_i, i \in \mathcal{J}^{(k)})$, (10).

5: **end for**

6: $\hat{k} = \arg \min_k \delta_R(\mathbf{P}, \mathbf{P}_{\mathcal{G}}^{(k)})$, (4).

7: **return** \hat{k}

Invarianza a la transformación



Fuente: [Congedo et al., 2017]

1 Geometría Riemanniana

2 Desafíos de ML en BCI


1 Geometría Riemanniana

2 Desafíos de ML en BCI


Variabilidad entre sesiones

Cross-session BCI

Session 1



Session 2




Session n



...

Variabilidad entre sesiones


Cross-session BCI



Domain adaptation, domain invariant, model robustness


Variabilidad entre sujetos

Cross-subjects BCI




Variabilidad entre sujetos

Cross-subjects BCI




Transfer learning, zero-training, minimal-recalibration

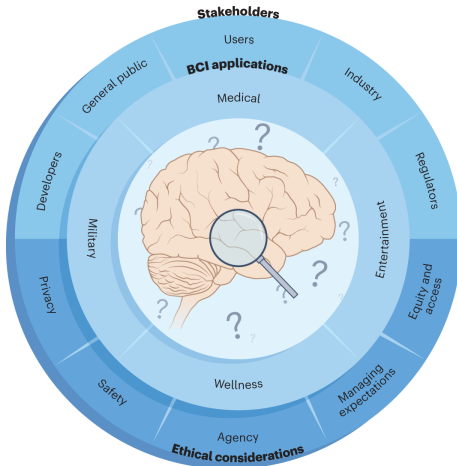
Considering the user within the loop



Considering the user within the loop



Feedback, model adaptability, illiteracy



Fuente: [Cabrera and Weber, 2023]

Y muuucho más



Fuente: [REVISTA KNOWABLE](#)

Bibliografía utilizada I

Barachant, A., Bonnet, S., Congedo, M., and Jutten, C. (2010). Riemannian geometry applied to bci classification. In *International Conference on Latent Variable Analysis and Signal Separation*, pages 629–636. Springer.

Cabrera, L. Y. and Weber, D. J. (2023). Rethinking the ethical priorities for brain–computer interfaces. *Nature Electronics*, 6(2):99–101.

Congedo, M., Barachant, A., and Bhatia, R. (2017). Riemannian geometry for eeg-based brain-computer interfaces; a primer and a review. *Brain-Computer Interfaces*, 4(3):155–174.